STHGCN

摘要

本文提出一种时空超图卷积网络，是第一个用于股票趋势预测的神经超图模型。在该模型中，作者设计了门控时间卷积，用于以时间顺序的方式学习股票关系上的股价演化。

研究背景

- 问题定义
  - 股票价格走势预测
  - $$Y = \begin{cases} \text{up}, & r_t > l_1 \\ \text{neutral}, & l_2 < r_t \le l_1 \\ \text{down}, & r_t \le l_2 \end{cases} \qquad r_t = \frac{p_t - p_{t-1}}{p_{t-1}}$$
- 现状
  - 大多数现有研究将股票视为相互独立的，或者通过图以成对的方式将对股票之间股价的高阶关系
  - 在对股票间关系建模时，缺乏对股票价格时间演变的时间顺序建模
- 动机
  - 以超图来捕获股票间复杂的高阶关系
  - 在超图上通过门控的时间卷积捕获时序特征
- 图卷积（GCN）
  - 图 G = (V, E, W)
    - V 节点集
    - E 边集
      - e <v1, v2>
    - W 边的权重
  - 图结构数据的表示

Labeled graph	Degree matrix	Adjacency matrix	Laplacian matrix
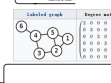	$\begin{pmatrix} 2&0&0&0&0&0 \\ 0&3&0&0&0&0 \\ 0&0&2&0&0&0 \\ 0&0&0&3&0&0 \\ 0&0&0&0&3&0 \\ 0&0&0&0&0&1 \end{pmatrix}$	$\begin{pmatrix} 0&1&0&0&1&0 \\ 1&0&1&0&1&0 \\ 0&1&0&1&0&0 \\ 0&0&1&0&1&1 \\ 1&1&0&1&0&0 \\ 0&0&0&1&0&0 \end{pmatrix}$	$\begin{pmatrix} 2&-1&0&0&-1&0 \\ -1&3&-1&0&-1&0 \\ 0&-1&2&-1&0&0 \\ 0&0&-1&3&-1&-1 \\ -1&-1&0&-1&3&0 \\ 0&0&0&-1&0&1 \end{pmatrix}$

    - 度矩阵
    - 邻接矩阵 — 反映节点与节点之间的关系
    - 拉普拉斯矩阵 — D - A
  - H — 节点的特征矩阵，维度为（n * d），n代表节点个数，d代表每个节点的特征维度
  - 图卷积通式 $H^{l+1} = f(H^l, A)$
  - 实现
    - 实现一 $H^{l+1} = \sigma(AH^lW^l)$
      - W是神经习参数
      - 缺点
        - 没有考虑节点自身对自己的影响
        - A没有被规范化，这样邻居节点多的节点倾向于具有更大的影响力
    - 实现二 $H^{l+1} = \sigma(LH^lW^l) \qquad L = D - A$ — 引入度矩阵，考虑了节点信息自传递的问题
    - 实现三 $H^{l+1} = \sigma(D^{-\frac{1}{2}}\tilde{A}D^{-\frac{1}{2}}H^lW^l)$
      - $L^{sym} = D^{-\frac{1}{2}}\tilde{A}D^{-\frac{1}{2}} = D^{-\frac{1}{2}}(D-A)D^{-\frac{1}{2}} = I_n - D^{-\frac{1}{2}}AD^{-\frac{1}{2}}$ — 对称归一化的拉普拉斯算子
- 超图（Hypergraph）

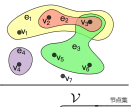

  - 形式化 $\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathbf{W})$
    - $\mathcal{V}$ 节点集
    - $\mathcal{E}$ 超边集
      - e {v_1, v_2, v_3, ..., v_m}
    - $\mathbf{W}$ 超边的权重

    "超边不是边，是节点的集合"
  - 图结构的数据表示
    - $\mathbf{H} \in \mathbb{R}^{|\mathcal{V}|\times|\mathcal{E}|}$ 关联矩阵（incidence matrix） — 反映节点与边之间的关系
      - $h(v,e) = \begin{cases} 1, & v \in e \\ 0, & v \notin e \end{cases}$
    - $\mathbf{D}_v \in \mathbb{R}^{|\mathcal{V}|\times|\mathcal{V}|}$ 节点度矩阵
      - $d(v) = \sum_{e\in\mathcal{E}} w(e)h(v,e) = \sum_{e\in\mathcal{E}} h(v,e)$
        - 对角矩阵
        - 一个节点在几个超边中，该节点的度就为几
    - $\mathbf{D}_e \in \mathbb{R}^{|\mathcal{E}|\times|\mathcal{E}|}$ 超边度矩阵
      - $\delta(e) = \sum_{v\in\mathcal{V}} h(v,e)$
        - 对角矩阵
        - 一个超边中有几个节点，那么该超边的度就为几
    - $\boldsymbol{\theta} = \mathbf{D}_v^{-1/2}\mathbf{H}\mathbf{W}\mathbf{D}_e^{-1}\mathbf{H}^T\mathbf{D}_v^{-1/2}$ 拉普拉斯矩阵
    - 节点表示 $\mathbf{x} = (\mathbf{x}_1, \mathbf{x}_2 \ldots \mathbf{x}_{|\mathcal{V}|})$

模型介绍

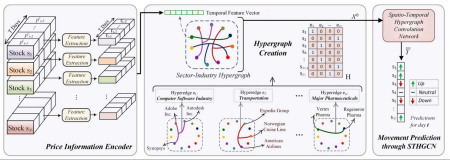

- overview
  - 以股票为节点，以行业为超边构建超图 — 每个股票只属于一个行业
- 超图卷积的实现 $\mathbf{Q} = \boldsymbol{\Theta} * \mathbf{X} = \mathbf{D}_v^{-1/2}\mathbf{H}\mathbf{W}\mathbf{D}_e^{-1}\mathbf{H}^T\mathbf{D}_v^{-1/2}\mathbf{X}\boldsymbol{\Theta}$
  - * 代表对X进行超图卷积
  - $\boldsymbol{\Theta} \in \mathbb{R}^{C\times F}$ 待学习参数
    - C 是输入特征的维度
- HGCN
  - 整体思路 — 先利用GRU提取时序依赖，然后利用HGCN捕取空间依赖
  - GRU — 用于提取时序依赖
  - HGCN — 将GRU的最后一层作为输入，进行超图卷积，然后直接进行预测
  - 缺点 — 基于RNN的模型速度较慢

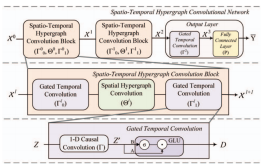

- STHGCN
  - 架构图

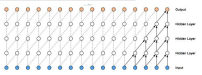

Figure 2: Visualization of a stack of causal convolutional layers.

  - 因果卷积，相互独立的作用在每一个股票上
  - 门控时卷积
    - 卷积核 $\boldsymbol{\Gamma} \in \mathbb{R}^{K_t\times C\times 2F}$
    - 输入 $\mathbf{Z} \in \mathbb{R}^{T\times C}$
    - 卷积结果 $\mathbf{Z}' \in \mathbb{R}^{(T-K_t+1)\times 2F}$ — A, B — $\mathbf{A}, \mathbf{B} \in \mathbb{R}^{(T-K_t+1)\times F}$
    - 门控输出 $\mathbf{D} = \boldsymbol{\Gamma} *_{\mathcal{T}} \mathbf{Z} = \mathbf{A} \cdot \sigma(\mathbf{B})$

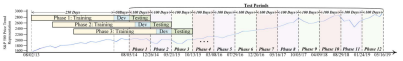

Fig. 5: Visualization of the dataset arrangement for all experiments covering 12 diverse phases of market activity. The blue line indicates the varying daily close price for the S&P 500 index.

实验与分析

- 样本部分

TABLE I: Statistics about the Hypergraph

Hyperedge Property	*Value*
Number	110
Max. Degree	28
Mean Degree	3.845

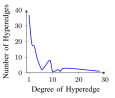

Fig. 6: Hyperedge degree distribution

- 数据分布
- 评价指标
  - F1
  - 市场模拟 — 以预测结果为指导进行股票的买入与做空操作，根据盈利情况进行评价

Phase	MLP [41]	HOIStage [48]	CNN [42]	LSTM [29]	GCN [11]	GCN2 [4]	TGC [15]	HATS [1]	HGCN	STHGCN
1	0.355	0.260	0.260	0.260	0.260	0.260	0.260	0.260	0.260	**0.260**
2	4.366	0.271	0.151	0.525	4.587	0.534	0.589	0.155	0.515	**4.142**
3	0.736	0.277	0.394	0.586	0.300	0.501	0.221	0.318	0.329	**0.335**
4	0.243	0.286	0.135	0.033	0.212	0.049	0.033	0.038	0.039	**0.046**
5	0.207	0.286	0.135	0.033	0.212	0.049	0.033	0.038	0.039	**0.046**
6	0.286	0.227	0.157	0.023	0.251	0.014	0.088	0.109	0.108	**0.081**
7	0.286	0.227	0.157	0.023	0.251	0.014	0.088	0.109	0.108	**0.081**
8	1.286	0.284	0.121	0.323	0.387	0.334	0.389	0.325	0.127	**0.255**
9	0.274	0.276	0.129	0.579	0.246	0.318	0.285	0.322	0.389	**0.135**
10	0.274	0.276	0.129	0.579	0.246	0.318	0.285	0.322	0.389	**0.135**
11	0.329	0.251	0.327	0.100	0.271	0.505	0.258	0.509	**0.329**	0.377
12	0.368	0.270	0.392	0.397	0.296	0.527	0.527	0.648	0.532	**0.541**
Average	0.717	0.267	0.302	0.311	0.265	0.332	0.295	0.328	0.332	**0.346**

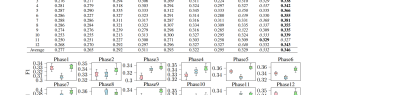

Fig. 7: Distribution of F1 scores with confidence intervals of the state-of-the-art model HATS (left, red), our proposed models HGCN (middle, blue) and STHGCN (right, green) over 10 different runs. Notched box plots best viewed in color.

- F1

Phase	LSTM	GCN	GCN2)	TGC	HATS	STHGCN
1	2.355	−0.260	−1.101	−0.510	**2.479**	2.475
2	4.065	2.47	**4.980**	3.052	4.590	3.031
3	1.064	−0.247	0.299	−0.170	**1.250**	1.146
4	2.301	0.038	0.317	−0.105	2.196	**2.436**
5	−0.145	−0.320	0.022	−0.105	0.404	**1.639**
6	0.858	0.457	−0.910	−0.443	2.043	**2.357**
7	0.858	0.457	−0.910	−0.443	2.057	**2.221**
8	2.197	1.574	1.037	**4.131**	1.483	1.269
9	0.491	0.776	−0.009	−0.301	0.606	**1.745**
10	−0.567	0.326	1.357	−1.202	1.439	**2.036**
11	−0.106	2.578	1.305	2.67	**3.614**	2.761
12	0.633	0.806	−0.820	1.779	1.961	**1.967**
Average	1.152	0.780	0.958	1.002	1.961	**2.065**

- 盈利情况